RAG 检索链路设计笔记

本文记录知识库问答系统在检索链路上的一组设计取舍，作为实现与验收的对照材料。内容按"切片—向量—融合—生成"的顺序组织。

1 切片策略

1.1 为什么按结构切

固定长度切分的根本问题不在于"长度不合适"，而在于它不知道文本里哪一处是断点。当一段正文被从中间切开时，前半段失去结论、后半段失去前提，两段都检索不到；更糟的是章节标题常常被留在上一段的末尾，于是这一段正文彻底失去了"它在讲什么"的线索。

按结构切分把标题当作正文的锚点：标题向下归属于它引领的正文，正文在自然段边界处断开。这样每个切片都自带上下文，单独拿出来也能读懂。

1.2 重叠区间的作用

重叠解决的是"答案恰好横跨两个切片"的问题。一个问题的答案往往由相邻两段共同构成，如果两段被切在不同的切片里，任一单独切片都不足以支撑回答。重叠区间让这类答案至少在一个切片内完整出现。

重叠的代价同样明确：token 总量上升，入库时间和存储成本随之增加；重叠过大时，检索结果里会出现大量内容近似甚至完全相同的切片，反而挤占了真正有用的候选位置。经验上重叠控制在目标大小的百分之十五到二十五之间较为稳妥，但这不是可以照抄的数字，需要用真实语料验证。

2 向量检索

2.1 索引选型

HNSW 与 IVFFlat 的核心差别在于是否需要训练。IVFFlat 需要先用已有数据聚类出若干中心点，数据量少或分布变化时召回率会明显下降；HNSW 用图结构组织向量，插入即生效，不需要预先训练，召回率也更高，代价是构建更慢、内存占用更大。对于持续增量入库的知识库，HNSW 的免训练特性比构建速度更重要。

2.2 距离度量

余弦距离衡量方向，欧氏距离衡量绝对位置。文本向量的模长往往不携带语义信息，因此先做归一化再比较方向更稳定。归一化之后，余弦距离与欧氏距离的排序结果一致，此时选哪个只影响实现细节，不影响召回顺序。

3 混合检索与融合

纯向量检索擅长语义相近但用词不同的情况，例如问"怎么防止模型胡说"能召回到讲"拒答"的段落。纯关键词检索擅长精确匹配，例如产品型号、错误码、专有名词这类向量模型没有充分学习的字符串。

两条通道的分数不可直接相加：向量相似度落在零到一之间，全文检索的排名分数没有固定上界，量纲完全不同。做加权求和就必须先归一化，而归一化本身会引入新的取舍。

倒排融合绕开了这个问题。它不使用分数，只使用每条候选在各通道中的排名位置，把排名倒数相加作为融合分。分数尺度的差异因此被完全消除，这也是它在工程上比加权求和更省心的原因。

4 生成与引用

4.1 引用编号的来源

引用编号必须由系统生成，不能由模型自行发明。上下文里的每个切片在拼接时就被赋予编号，模型只被允许引用已存在的编号。生成之后还要做一次校验：凡是模型提到但上下文里不存在的编号，一律剔除或整段重答。

4.2 拒答的判定

拒答阈值定得太低，系统会对明明有依据的问题说"查不到"；定得太高，它会开始用通用知识编造文档里没有的内容。两种错误里，编造更难被发现，因此阈值应当偏保守，宁可多拒几次。

仅靠相似度阈值判定是不够的：相似度高的切片可能只是用词接近而主题无关。更稳的做法是让模型在生成之前先判断给定证据是否足以回答问题，再由程序合并这两路结论。

5 参数速查

环节	参数	说明

切片 target 目标大小，在语义断点处尽量靠近

切片 max 硬上限，超过即为缺陷

切片 overlap 重叠量，代价是 token 总量上升

向量 m HNSW 每层出边数，越大召回越高、内存越多

融合 k 排名平滑常数，取零会让第一名过度主导